

Aplicação de *Machine Learning* para Estimação de Canal e Equalização de um Sistema *Fiber-wireless*.

Nome: Luiz Augusto Melo Pereira

Matrícula: 20

Título do artigo: Deep Learning-Based Channel Estimation

Autores do artigo: Mehran Soltani, Vahid Pourahmadi,
Ali Mirzaei, Hamid Sheikhzadeh.

28 de agosto de 2020

A técnica de multiplexação por divisão em frequências ortogonais (OFDM) é amplamente utilizada em sistemas de comunicações sem fio. Nesta técnica, a banda do sinal a ser transmitido é dividida em múltiplas subbandas ortogonais. Esta abordagem aumenta a probabilidade de cada portadora sofrer um desvanecimento plano do canal. Esta característica contribui para que a forma de onda OFDM seja amplamente utilizada em sistemas de comunicações sem fio por apresentar um ótimo desempenho em canais seletivos em frequências devido à múltiplos percursos. Outra vantagem no uso de subbandas refere-se a equalização do canal. Ao utilizar múltiplas portadoras, simplifica-se o processo de equalização no domínio da frequência, visto que o desvanecimento seletivo afetará apenas algumas portadoras do sinal. Logo, é possível estimar a resposta de frequência do canal para cada portadora individualmente e aplicar equalizadores mais simples em comparação aos utilizados em sinais com portadora única.

Para estimar a resposta do canal, adiciona-se portadoras pilotos entre as portadoras de dados. Estas portadoras pilotos possuem valor conhecido pelo receptor, logo, nas posições das portadoras pilotos é possível obter a resposta do canal. Nas demais posições, ou seja, para as portadoras de dados, obtém-se a estimativa do canal realizando uma interpolação entre portadoras pilotos. As distorções do canal podem ser compensadas utilizando a equalização no domínio da frequência por meio da técnica *zero forcing* (ZF), por exemplo. Vale ressaltar que o aumento do número de portadoras aumenta a precisão da estimativa do canal ao custo de reduzir-se a eficiência espectral, uma

vez que a banda disponível será utilizada para transmissão de dados não úteis. Alguns autores propõem técnicas distintas de obter-se a estimativa do canal ou otimizar o uso das portadoras pilotos com o objetivo de maximizar a eficiência espectral. Dentre essas técnicas destaca-se o uso de *machine learning* para estimar e equalizar canais.

Recentemente, a técnica *deep learning* em conjunto com transmissões OFDM, tem atraído bastante atenção em várias áreas de estudo. Esta técnica utiliza diversas camadas de aplicações nas quais são realizadas operações computacionais simples como multiplicação de vetores e matrizes. Alguns autores defendem o uso de *deep learning* para estimação de canais sem fio e demonstram estimativas mais precisas em comparação às técnicas convencionais de estimação [1, 2]. Outros trabalhos demonstram a possibilidade de aprimorar a detecção de símbolos utilizando *deep learning* e consequentemente, reduzir a taxa de erro de bits (BER) ou símbolos (SER) [3, 4].

O uso de *deep learning* não se restringe a estimação de canais e detecção de símbolos em sistemas de comunicações, esta técnica também pode ser utilizada para auxiliar outras funcionalidades dos sistemas de comunicações móveis. Por exemplo, *deep learning* pode ser eficientemente aplicada para estimação de canais para sistemas que empregam múltiplas portadoras de transmissão e recepção (MIMO) [5, 6] e redes veiculares [7]. Em paralelo, alguns autores defendem o uso de técnicas de *machine learning*, incluindo *deep learning*, em sistemas de comunicações ópticas. Dessa forma, sistemas radio sobre fibra (RoF) podem ser linearizados com o objetivo de reduzir os efeitos lineares e não lineares presentes neste tipo de sistema de comunicação [8, 9].

Este documento apresenta uma proposta para o trabalho prático da disciplina TP-555. A proposta consiste na utilização de técnicas de *machine learning*, especialmente *deep learning*, para auxiliar a estimação e equalização de um sistema *fiber-wireless* apresentado na Figura 1. Em tal sistema, um sinal OFDM é gerado utilizando Matlab ou Python e adicionado ao Optisystem. O Optisystem é uma ferramenta computacional, que possibilita simular sistemas de comunicações nos domínios elétrico e, principalmente, óptico a partir de uma biblioteca de componentes. Dentre estes componentes cita-se: geradores de bits, moduladores digitais, fontes luminosas, moduladores eletro-ópticos, fibras ópticas, fotodetectores, filtros digitais e outros. Embora o Optisystem possua uma extensa biblioteca de componentes ópticos e elétricos, esta ferramenta é limitada em termos de geração de formas de ondas. Porém, alguns componentes da biblioteca permitem a co-simulação com programas computacionais externos e com diferentes linguagens de programação, como por exemplo o Matlab e o Python. Com isto, pode-se utilizar o Matlab ou Python para gerar sinais, demodular sinais e emular canais sem

fibro, enquanto que o Optisystem pode ser utilizado para implementar o sistema óptico de transporte de sinais. Portanto, o uso conjunto dos softwares permite emular um sistema *fiber-wireless*. Propõe-se então utilizar técnicas de *machine learning* como por exemplo, *deep learning* para estimação e equalização de canal para um sistema *fiber-wireless* composto pelos canais óptico e sem fio. Por conseguinte, espera-se obter melhorias no desempenho do sistema em termos de BER e da magnitude do vetor de erro (EVM), ao aplicar técnicas de *machine Learning*.




Figura 1: Diagrama em blocos do sistema *fiber-wireless* proposto: LD- laser; MZM- modulador de Mach-Zehnder; SMF- *single mode fiber*; PD- *photodetector*; EA- *electrical amplifier*

Finalmente, propõem-se utilizar alguns conceitos de processamento de imagens para obter-se uma estimativa do canal a partir das portadoras pilotos. Para tal, propõe-se utilizar algumas técnicas de processamento de imagens conforme apresentado em [10]. Portanto, pode-se criar uma rede *deep learning* com camadas que utilizam técnicas como, *image super-resolution* (SR) e *image-restoration* (IR), para obter-se estimativas dos canais óptico e sem fio. A estimativa é feita considerando todos os valores conhecidos das portadoras piloto como uma imagem bidimensional de baixa resolução. Esta imagem de baixa resolução é aplicada à uma rede de SR em cascata com uma rede IR para aumentar a resolução e restaurar a imagem, a qual irá corresponder a uma estimativa da resposta do canal.

Referências

- [1] Y. Yang, F. Gao, X. Ma, and S. Zhang, “Deep learning-based channel estimation for doubly selective fading channels,” *IEEE Access*, vol. 7, pp. 36 579–36 589, 2019.

- [2] J. Liu, K. Mei, X. Zhang, D. Ma, and J. Wei, "Online extreme learning machine-based channel estimation and equalization for ofdm systems," *IEEE Communications Letters*, vol. 23, no. 7, pp. 1276–1279, 2019.
- [3] H. Ye, G. Y. Li, and B. Juang, "Power of deep learning for channel estimation and signal detection in ofdm systems," *IEEE Wireless Communications Letters*, vol. 7, no. 1, pp. 114–117, 2018.
- [4] A. C. Najarro and S.-M. Kim, "Nonlinear compensation using artificial neural network in radio-over-fiber system," *Journal of information and communication convergence engineering*, vol. 16, no. 1, pp. 1–5, 2018.
- [5] . T. Demir and E. Björnson, "Channel estimation in massive mimo under hardware non-linearities: Bayesian methods versus deep learning," *IEEE Open Journal of the Communications Society*, vol. 1, pp. 109–124, 2020.
- [6] E. Balevi, A. Doshi, and J. G. Andrews, "Massive mimo channel estimation with an untrained deep neural network," *IEEE Transactions on Wireless Communications*, vol. 19, no. 3, pp. 2079–2090, 2020.
- [7] S. Han, Y. Oh, and C. Song, "A deep learning based channel estimation scheme for ieee 802.11p systems," in *ICC 2019 - 2019 IEEE International Conference on Communications (ICC)*, 2019, pp. 1–6.
- [8] M. U. Hadi, "Assessment of linearity improvement in optical communication systems with machine learning methods," 2019.
- [9] Y. Huang, Y. Chen, and J. Yu, "Nonlinearity mitigation of rof signal using machine learning based classifier," in *2017 Asia Communications and Photonics Conference (ACP)*. IEEE, 2017, pp. 1–3.
- [10] M. Soltani, V. Pourahmadi, A. Mirzaei, and H. Sheikhzadeh, "Deep learning-based channel estimation," *IEEE Communications Letters*, vol. 23, no. 4, pp. 652–655, 2019.